



UPA - projekt 3

Team - xkotou08

Předzpracování: příprava dat (3. část; Burgetová)

Lukáš Kotoun - xkotou08

Jan Pánek - xpanek11

Jiří Kantor - xkanto16

17. září 2026

1 Explorativní analýza

Pro analýzu byla použita veřejná datová sada **Stroke Prediction Dataset** ze stránky Kaggle, která je určena k trénování modelů na predikci cévních mozkových příhod.

Atributy datové sady

Z vypsaných informací lze vyčíst, že datová sada obsahuje 12 atributů, z toho 5 je kategorických a 7 číselných, a že obsahuje informace celkem o 5110 osobách. O každé osobě se uvádějí základní informace, jako je pohlaví, věk nebo typ práce, a následně několik zdravotních informací, které by mohly souviset s výskytem mozkové příhody. Obsahuje také sloupec, zda se u této osoby mozková příhoda vyskytla, či nikoliv. U sloupce BMI vidíme, že tento atribut není pro některé osoby vyplněn.

Název sloupce	Datový typ	Počet hodnot
gender	object	5110
age	float64	5110
hypertension	int64	5110
heart_disease	int64	5110
ever_married	object	5110
work_type	object	5110
Residence_type	object	5110
avg_glucose_level	float64	5110
bmi	float64	4909
smoking_status	object	5110
stroke	int64	5110

Tabulka 1: Typy a počty atributů datové sady

gender	age	hyper	heart	married	work_type	resid.	glucose	bmi	smoking	stroke
Male	67.0	0	1	Yes	Private	Urban	228.69	36.6	formerly smoked	1
Female	61.0	0	0	Yes	Self-employed	Rural	202.21	NaN	never smoked	1
Male	80.0	0	1	Yes	Private	Rural	105.92	32.5	never smoked	1
Female	49.0	0	0	Yes	Private	Urban	171.23	34.4	smokes	1
Female	79.0	1	0	Yes	Self-employed	Rural	174.12	24.0	never smoked	1

Tabulka 2: Ukázka prvních 5 záznamů z datové sady

Na základě popisné statistiky dat vidíme, že osoby mají průměrný věk 43 let, průměrnou hladinu glukózy v krvi 106 mg/dl a medián body mass indexu 28, což značí, že průměrná osoba v datové sadě bojuje s nadváhou. Také lze vyčíst, že většina osob, o kterých máme údaje, jsou ženy (konkrétně 59%) a většina osob (63%) jsou nebo byly kuřáci. Také vidíme, že mozková příhoda se vyskytla pouze u 4.9% osob, a tedy datová sada je vzhledem k tomuto důležitému atributu velmi nevyvážená.

Atribut	Počet	Průměr	Std. odch.	Min	25%	50%	75%	Max
age	5110	43.23	22.61	0.08	25.00	45.00	61.00	82.00
avg_glucose_level	5110	106.15	45.28	55.12	77.25	91.89	114.09	271.74
bmi	4909	28.89	7.85	10.30	23.50	28.10	33.10	97.60

Tabulka 3: Popisná statistika numerických atributů

Atribut	Počet	Unikátní	Nejčastější (Top)	Frekvence
gender	5110	3	Female	2994
ever_married	5110	2	Yes	3353
work_type	5110	5	Private	2925
Residence_type	5110	2	Urban	2596
smoking_status	5110	4	never smoked	1892
c_hypertension	5110	2	No	4612
c_heart_disease	5110	2	No	4834
c_stroke	5110	2	No	4861

Tabulka 4: Popisná statistika kategorických atributů

Analýza pomocí grafů

Skupina grafů 1 zachycuje význam jednotlivých atributů při určování rizika mozkové příhody. Pro žádný atribut nelze říci, že určité hodnoty atributu jednoznačně určují, že pro danou osobu byla zaznamenána mozková příhoda. Lze pouze konstatovat, že pro určité hodnoty atributů stoupá riziko mozkové příhody. Nejvýznamnější indikátory jsou pak věk (age), vysoký krevní tlak (hypertension) a srdeční onemocnění (heart disease).


Naopak pro atributy bydliště (residence type) a pohlaví (gender) je zastoupení mozkových příhod pro jednotlivé třídy podobné, tedy na základě hodnot těchto atributů nelze určit, zda je riziko mozkové příhody vyšší. Stejně tak na základě numerického atributu bmi a průměrné hladiny glukózy v krvi (avg glucose level) nelze určit zvýšené riziko mozkové příhody. Toto tvrzení je dále podpořeno grafem 6.

Níže na atributu typ zaměstnání (work type) demonstrujeme skutečnost, že zvýšené zastoupení výskytu mozkové příhody pro některé třídy kategorických atributů je podmíněno vyšším zastoupením osob v pokročilém věku pro dané třídy.


Graf 2 zachycuje, že pro jednotlivé typy zaměstnání se mozková příhoda vyskytuje zejména u osob v pokročilém věku, a tedy typ zaměstnání nemá smysl uvažovat jako indikátor pro zvýšenou pravděpodobnost mozkové příhody. Poznamenejme, že pro children byly zaznamenány pouze 2 ojedinělé případy s mozkovou příhodou, a tedy boxploty pro třídu children nejsou v konfliktu s naším tvrzením.

Následující dvojice grafů 3 zobrazuje procentuální zastoupení osob s mozkovou příhodou v určitých skupinách. Na levém grafu můžeme pozorovat, že lidé, kteří netrpí ani na vysoký krevní tlak, ani na srdeční onemocnění, mají značně menší riziko mozkové příhody v porovnání s lidmi s jednou z těchto nemocí nebo s oběma.

Na pravém grafu vidíme rozdělení do skupin na základě vztahu ke kouření a typu bydliště. Vidíme, že kuřáci, kteří dříve kouřili a již přestali, mají v porovnání s ostatními skupinami zvýšené riziko mozkové příhody, což může být také ovlivněno vyšším věkem této skupiny. Lze




Obrázek 1: Rozložení hustoty pravděpodobnosti pro numerické atributy s odlišením výskytu mozkové příhody a zastoupení výskytu mozkové příhody pro jednotlivé třídy u kategorických atributů.



Obrázek 2: Rozložení věku pro jednotlivé typy zaměstnání s rozlišením výskytu mozkové příhody. Pro děti s mozkovou příhodou byly zaznamenány 2 ojedinělé případy.

také pozorovat, že bydliště má na sledované riziko pouze minimální vliv.




Obrázek 3: Procentuální zastoupení lidí s mozkovou příhodou v různých skupinách. Skupiny v levém grafu tvoří kombinace hodnot atributů, které značí srdeční nemoc a vysoký krevní tlak. Skupiny v pravém grafu tvoří kombinace hodnot atributů, které značí vztah ke kouření a typ bydliště.

Z dvojice grafů 4 lze zjistit zajímavé skutečnosti, které datová sada skrývá. Z levého grafu můžeme pozorovat, že sada obsahuje osoby ve věku 15 let, které aktivně kouří, více znepokojující však může být, že obsahuje i osoby stejného věku, které s kouřením již přestaly, a tedy musely kouřit již v dřívějším věku.

Pravý graf ukazuje, že mediánová hodnota BMI u pracujících osob se pohybuje na hranici

nadváhy a obezity prvního stupně, zatímco mediánová hodnota pro osoby, které nikdy nepracovaly (převážně věková skupina studentů), se pohybuje ve zdravém rozmezí. Z toho lze usuzovat silnou korelaci mezi nástupem do zaměstnání (a s tím spojenou změnou denního režimu) a zhoršováním fyzické kondice.



Obrázek 4: Grafy zobrazující zajímavé vztahy mezi atributy. Levý graf zobrazuje závislost mezi vztahem ke kouření a věkem. Pravý graf zobrazuje vztah mezi typem zaměstnání a hodnotou BMI.


Analýza odlehlých hodnot

K detekci odlehlých hodnot u atributů glukózy, věku a BMI byla využita metoda Z-score. Ta byla upřednostněna před metodou IQR, která se ukázala jako velmi restriktivní. Analýza pomocí Z-score odhalila celkem 49 chybějících hodnot u hladiny glukózy (např. 252.72; 243.58 a 259.63) a 58 hodnot u BMI (chybějících hodnot: 56.6; 54.6 a 60.9).

Proměnná	Metoda	Počet odlehlých	Ukázka hodnot
Věk	IQR	0	[]
	Z-Score	0	[]
Průměrná hladina glukózy	IQR	627	[228.69, 202.21, 171.23, 174.12, 186.21]
	Z-Score	49	[252.72, 243.58, 259.63, 249.31, 263.32]
BMI	IQR	110	[48.9, 56.6, 50.1, 54.6, 60.9]
	Z-Score	58	[56.6, 54.6, 60.9, 54.7, 64.8]

Tabulka 5: Přehled odlehlých hodnot podle IQR a Z-score

Na analýzu odlehlých hodnot u kategoričkových atributů reprezentujících pohlaví, typ zaměstnání, oblast bydlení a vztah ke kouření bylo použito zobrazení zastoupení jednotlivých kategorií pomocí histogramu. U kategorií oblast bydlení a vztah ke kouření nebyly nalezeny žádné odlehlé hodnoty. U pohlaví byla u 1 osoby nalezena odlehlá hodnota **Other**. Pro typ zaměstnání byla u 22 osob nalezena odlehlá hodnota **never_worked**.



Obrázek 5: Histogramy kategoričských atributů pro detekci odlehlých hodnot


Analýza chybějící hodnot

Chybějící hodnoty v datasetu byly lokalizovány pouze u sloupce bmi, pro které byly chybějící hodnoty označeny jako "N/A", a pro sloupec smoking_status, kde byly hodnoty označeny jako "Unknown".


Celkově bylo nalezeno 1745 chybějících hodnot, z nichž bylo 201 u bmi a 1544 u smoking_status. Bylo nalezeno 61 objektů (řádků), které mají chybějící hodnotu v obou těchto sloupcích současně.

Korelační analýza

Korelační analýzu jsme provedli pomocí bodového grafu 6 a korelačních koeficientů 7. Ani jedna metoda neodhalila žádnou významnou korelaci mezi numerickými atributy.



Obrázek 6: Bodový graf pro páry numerických atributů věk (age), bmi a průměrná hladina glukózy v krvi (avg glucose level) s rozlišením případů výskytů mozkové příhody.



Obrázek 7: Korelační matice pro numerické atributy věk(age), bmi a průměrná hladina glukózy v krvi (avg glucose level).

2 Příprava 2 datových sad na dolování

Příprava dat bude zaměřena na úpravu datové sady pro účely natrénování modelu na predikci rizika vzniku mozkové příhody.

Odstranění irelevantních atributů

Na základě analýzy grafu 1, který zachycuje zastoupení výskytu mozkové příhody pro pozorované atributy, označujeme pohlaví a bydlení za irelevantní atributy, jelikož zastoupení výskytu mozkové příhody pro jednotlivé hodnoty těchto atributů je velmi podobné. Pro žádnou hodnotu daného atributu nelze předpokládat větší pravděpodobnost mozkové příhody oproti ostatním hodnotám.

Dále byl odstraněn atribut typ zaměstnání, jelikož na základě grafu 2 usuzujeme, že výskyt mozkové příhody je spíše podmíněn věkem než typem zaměstnání.

Poznamenejme, že na základě 1 a 6 lze usoudit, že bmi i průměrná hladina glukózy v krvi také nemá na výskyt mozkové příhody vliv, jelikož rozložení hodnot bmi pro záznamy s i bez mozkové příhody je podobné. Atribut bmi je ale jediný s chybějícími hodnotami, a tedy byl pro účely možnosti plnění následujícího bodu "Vyřešení chybějících hodnot" ponechán. Stejně tak atribut zachycující průměrnou hladinu glukózy v krvi byl ponechán pro účely následujícího bodu "Diskretizace numerických atributů".

Vyřešení chybějících hodnot

Chybějící hodnoty, u kterých řešíme jejich doplnění, případně odstranění, jsou pouze v atributu BMI. Jednou metodou je odstranění celých záznamů s chybějícím BMI. Druhou použitou metodou je doplnění chybějících hodnot. Hodnoty, které jsou při doplňování použity, jsou vypočítány jako průměr BMI z věkové skupiny, do které daná osoba, jejíž BMI doplňujeme, spadá.

Dále zaznamenáváme chybějící hodnoty (unknown) pro atribut smoking status. Záznamy s unknown pro tento atribut tvoří kolem 30% datasetu, tedy není vhodné je odstranit a zároveň nemáme na základě čeho tyto hodnoty doplnit, rozhodli jsme se ponechat unknown jako separátní třídu.

Odstranění odlehlých hodnot

Odlehlé hodnoty byly identifikovány a odstraněny u atributů hladiny glukózy a BMI. Pro filtraci byla zvolena metoda Z-score. Metoda IQR se ukázala jako nevhodná a velmi restriktivní, jelikož u průměrné hladiny glukózy identifikovala jako odlehlé hodnoty více než 600 záznamů a u BMI více než 100 záznamů. Z-score umožnilo eliminovat pouze extrémní odchylky (pravděpodobné chyby měření) při zachování maximálního počtu validních dat.

i) Diskretizace numerických atributů a normalizace

Na diskretizaci numerických atributů byla zvolena metoda košů se stejnou četností (do hloubky). Tento přístup byl zvolen, neboť data mají nerovnoměrné rozložení, které by při dělení na intervaly stejné šířky vedlo k nevyváženému obsazení jednotlivých kategorií (košů).

ii) Převod kategorických atributů na numerické

Pro převod kategorických atributů na numerické byla použita metoda One-Hot Encoding. Metoda byla zvolena, neboť kategorické hodnoty obsažené v datové sadě nemají žádné pořadí a také mají menší počet unikátních hodnot, tedy nebude nutné vytvářet velké množství nových sloupců.

Numerické atributy byly normalizovány s využitím min-max normalizace. Uvažujeme, že pro predikci rizika bude použita neuronová síť, tedy je vhodné, aby jednotlivé atributy měly stejný rozsah hodnot. Jelikož odlehlé hodnoty byly odstraněny, lze tuto metodu bezpečně použít.